LAPORAN

ANALISIS DAN PREDIKSI CUSTOMER CHURN PADA KEPUASAN PELANGGAN MASKAPAI MENGGUNAKAN MACHINE LEARNING



Nama : Ravy Whienelda

NIM : 24.N1.0027

Mata Kuliah : Kecerdasan Bisnis

Program Studi : Sistem Informasi

Tahun : 2026

DAFTAR ISI

DAFTAR ISI **2**
BAB I INTRODUCTION **3**
1.1 Background 3
1.2 State Of The Art 4
1.3 Research Gap 4
1.4 Research Objectives 4
BAB II RELATED WORK **5**
2.1 Theoretical Foundation 5
2.2 Previous Studies 7
2.3 Comparative Analysis 8
BAB III RESEARCH METHODOLOGY **9**
3.1 Research Framework 9
3.2 Dataset and Data Collection 9
3.3 Data Preprocessing 11
3.4 Proposed Method 12
3.5 Experimental Design 13
3.6 Evaluation Matrics 13
BAB IV RESULTS **14**
4.1 Experimental Result 14
4.2 Comparative Performance 14
4.3 Statistical Validation 15
4.4 Sensitivity and Ablation Analysis 15
BAB V DISCUSSION **17**
5.1 Interpretation of Findings 17
5.2 Comparison with Previous Studies 18
5.3 Scientific and Practical Implications 18
5.4 Research Limitations 19
BAB VI CONCLUSION **19**
6.1 Research Limitations 19
6.2 Contribution 20
6.3 Future Research 20
LAMPIRAN **22**

BAB I INTRODUCTION

1.1 Background

Customer churn adalah kondisi ketika pelanggan berhenti menggunakan suatu produk maupun layanan, bak itu membatalkan langganan, tidak memperpanjang kontrak, beralih ke kompetitor, maupun berhenti transaksi sama sekali. Hal ini banyak dijumpai pada sebuah bisnis, tingkat churn atau disebut churn rate menjadi indikator pentingnya kesehatan suatu bisnis karena menunjukan seberapa baik mereka menjaga hubungan jangka panjang dengan pelanggan. Di jaman sekarang di tengah persaingan bisnis yang sangat ketat membuat banyak produk yang mirip dan harga yang lebih rendah membuat pelanggan dengan mudah mengganti dari produk a ke produk b sedangkan bagi bisnis mempertahankan pelanggan itu adalah hal yang tidak murah [1].

Mempertahankan pelanggan jauh lebih murah dan efisien dibandingkan mencari pelanggan baru. Biaya untuk mendapatkan pelanggan baru meliputi banyak biaya seperti pemasaran, promosi, insentif, dan proses onboarding. Selain itu pelanggan lama cenderung memberikan nilai positif seperti pembelian berulang dan yang terpending mereka bisa merekomendasikan produk tersebut ke orang lain, dengan begitu mempertahankan pelanggan bukanlah sekedar upaya untuk menekan kerugian melainkan strategi untuk membangun pertumbuhan bisnis yang berkelanjutan. Apalagi pada industri penerbangan biaya akuisisi penumpang baru 5–7x lipat lebih mahal dibanding retensi, sensitivitas terhadap ketepatan waktu, dan kualitas fasilitas kabin [3].

Tingginya tingkat churn akan membawa dampak negatif dan signifikan bagi perusahaan, hilangnya pelanggan berarti hilangnya pendapatan berulang sementara perusahaan harus terus mengeluarkan biaya untuk menggantikan pelanggan yang hilang tersebut. Menggantikan pelanggan berarti mengeluarkan biaya lagi untuk pemasaran bila itu terjadi terus menerus margin keuntungan juga akan terus terkikis. Selain itu pelanggan yang tidak puas juga akan berpotensi meninggalkan pendapat negatif pada merek dan merusak reputasi merek, churn yang sulit diprediksi ini mengisahkan perusahaan dalam memproyeksikan pendapat dan menyusun strategi. Oleh karena itu kemampuan untuk mengidentifikasi pelanggan yang berpotensi chun sebelum mereka benar-benar melakukannya akan menjadi keuntungan kompetitif yang penting bagi perusahaan [2].

Bekembangnya teknologi informasi memungkinkan perusahaan mengumpulkan data dalam jumlah yang besar dan beragam, mencangkup banyak hal seperti profil pelanggan, demografis, serta data kontrak dan langganan. Dengan data tersebut kita bisa melihat tanda awal ketidakpuasan seperti penurunan intensitas penggunaan, keterlambatan pembayaran, serta umur dari pengguna. Dengan adanya data ini dan dapat dianalisis dengan tepat, data ini dapat diproses untuk menjadi wawasan yang mendukung pengambilan keputusan berbasis data.

Dengan adanya data tersebut machine learning dapat berperan dengan penting untuk mencari penyebab churn. Algoritma seperti *Logistic regression, Random Forest, dan Gradient Boosting* mampu mengenali pola kompleks dan memproses data pelanggan dalam skala besar, serta menghasilkan skor probabilitas churn untuk setiap pelanggan sehingga perusahaan dapat bertindak untuk pelanggan dengan risiko churn tersebut. Selain itu model dapat dilatih ulang dengan data terbaru agar tetap relevan dan terus digunakan. Demikian penerapan *machine learning* memungkunkan peruashaan beraluh dari pendekatan reaktif menjadi proaktif sehingga tingkat churn bisa ditekan, biaya retensi bisa lebih efisien, dan profitabilitas jangka panjang dapat meningkat.

1.2 State Of The Art

Penelitian prediksi customer churn telah banyak berkembang dari model statistik tradisional menuju pendekatan machine learning. Algoritma seperti Logistic Regression lazim dijadikan pembanding dasar , sedangkan model berbasis pohon seperti Decision Tree dan Random Forest banyak digunakan [6] karena kemampuannya memproses relasi non-linear serta memberikan interpretasi variabel penting [4]. Perkembangan terkini menunjukkan bahwa integrasi pemodelan prediktif dengan sistem inferensi interaktif menjadi fokus penting agar hasil prediksi dapat dimanfaatkan langsung oleh unit operasional bisnis

1.3 Research Gap

Sebagian besar penelitian churn terdahulu berfokus pada industri telekomunikasi, perbankan, dan e-commerce dengan data langganan kontraktual. Penelitian churn pada maskapai seringkali terbatas pada analisis kepuasan deskriptif tanpa mengaitkannya dengan optimasi decision threshold. Standar threshold 0.50 kerap mengabaikan biaya asimetris bisnis, di mana kegagalan mendeteksi penumpang churn berakibat hilangnya pendapatan seumur hidup pelanggan. Selain itu, riset sebelumnya jarang menyediakan artefak deployment siap pakai berbasis antarmuka visual.

1.4 Research Objectives

1. Menganalisis karakter dan faktor penyebab ketidakpuasan/churn penumpang.
2. Membangun dan membandingkan performa model *Logistic Regression, Decision Tree, dan Random Forest.*
3. Mengoptimalkan *decision threshold* untuk menekan angka *false negative* pada retensi maskapai.
4. Mengimplementasikan model terbaik ke dalam aplikasi interaktif berbasis streamlit

BAB II RELATED WORK

2.1 Theoretical Foundation

Customer churn didefinisikan sebagai peristiwa berpindahnya pelanggan atau berhentinya penggunaan layanan suatu perusahaan menuju produk atau penyedia alternatif milik kompetitor. Dalam *Customer Relationship Management* churn dikelompokkan ke dalam dua kategori utama yaitu *Voluntary Churn* dan *Involuntary Churn* [5]. *Voluntary Churn* terjadi ketika pelanggan secara sadar dan sukarela memutuskan untuk menghentikan penggunaan layanan. Penyebab utamanya ada pada ketidakpuasan terhadap kualitas layanan, pengalaman pelanggan yang mengecewakan, harga yang tidak kompetitif, atau penawaran kompetitor yang lebih menarik. Sedangkan *Involuntary Churn* terjadi karena faktor eksternal di luar kendali langsung dari persepsi pelanggan seperti perpindahan domisili, perubahan kebijakan regulasi, ataupun finansial pribadi. Pada industri penerbangan mayoritas kejadian churn bersifat *voluntary churn* yang dipicu oleh akumulasi rasa kecewa penumpang terhadap pengalaman terbang langsung, layanan pemesanan secara *online*, maupun *delay* yang terjadi. Oleh karena tingkat ketidakpuasan digunakan sebagai proksi utama untuk risiko churn sebelum pelanggan benar benar berhenti menggunakan maskapai. Mengidentifikasi penumpang berisiko churn sejak dini memungkinkan maskapai mengalokasikan program retensi secara tepat sasaran guna menjaga *Customer Lifetime Value*.

2.1.1 Prediksi Churn Berbasis Machine Learning

Prediksi Churn Berbasis Supervised Machine Learning Prediksi churn dimodelkan sebagai persoalan klasifikasi terawasi. Pada pendekatan ini, data historis yang memuat sekumpulan atribut prediktor profil demografis, skor survei layanan, dan data operasional penerbangan yang sudah memiliki label status apakah penumpang merasa puas atau tidak puas. Tujuan dari model ini adalah mempelajari pola hubungan antara variabel-variabel layanan tersebut, model akan mengeluarkan probabilitas churn 0 hingga 100. Probabilitas ini kemudian dibandingkan suatu nilai ambang batas atau disebut *threshold* tertentu, jika probabilitas penumpang melebihi *threshold* maka sistem akan mengklasifikasikan penumpang sebagai beresiko churn.

2.1.2 Algoritma Klasifikasi Yang Digunakan

Untuk mendapatkan model dengan performa lain, dilakukan penelitian dengan membandingkan tiga algoritma klasifikasi yang memiliki cara kerja berbeda. *Logistic Regression* adalah algoritma klasifikasi berbasis statistik yang memetakan hubungan variabel input menjadi nilai peluang [7]. Pada penelitian ini *Logistic Regression* digunakan sebagai model pembanding dasar. Kelebihan algoritma ini terletak pada proses pelatihannya yang cepat dan mudah diinterpretasikan. Namun karena sifat dasarnya linier, model ini kurang optimal dalam menangkap pola perilaku kepuasan pelanggan yang seringkali bersifat non-linier dan saling berkaitan.

Sementara itu *Decision Tree* bekerja dengan cara membagi data secara bertingkat menggunakan aturan logika sederhana *if-then* menyerupai struktur rantai percabangan pohon [8]. Algoritma ini memilah variabel yang paling berpengaruh di setiap tingkatan untuk memisahkan pelanggan yang puas dan tidak puas. Keunggulan utama moel ini adalah alur keputusannya yang sangat transparan dan mudah dibaca secara visual, meski begitu *decision tree* memiliki kelebihan mudah mengalami overfitting, yaitu kondisi dimana model terlalu menghafal data sehingga performanya menurun saat menghadapi data baru.

Random Forest adalah metode ensemble yang mengatasi kelemahan *decision tree* dengan cara membangun ratusan pohon keputusan secara bersamaan. Masing-masing pohon dipilih menggunakan sampel data dari subset fitur yang dipilih secara acak. Keputusan akhir diprediksi diambil berdasarkan kesepakatan terbanyak atau rataa-rata prediksi dari seluruh pohon tersebut. Pendekatan ini membuat *random forest* sangat stabil, tidak mudah terkecoh oleh data *outlier* serta mampu memberikan akurasi prediksi yang jauh lebih tinggi dan konsisten.

2.1.3 Matriks Evaluasi Model dan Pentingnya Recall pada Bisnis Maskapai

Kinerja dari ketiga model klasifikasi diuji dengan menggunakan matrik evaluasi standar. *Accuracy* digunakan untuk menghitung persentase ketepatan model dalam memprediksi status penumpang secara keseluruhan, baik yang churn maupun tidak. *Precision* mengukur seberapa tepat prediksi model ketika menyatakan seorang penumpang akan churn dari seluruh penumpang yang tidak, berapa persen tebakan yang benar. *Recall* untuk mengukur kemampuan model dalam menangkap seluruh penumpang yang sesungguhnya mengalami churn, dari semua penumpang yang aslinya tidak puas, berapa banyak yang berhasil diambil oleh model. F1-Score yaitu nilai rata-rata harmonik yang menyeimbangkan *Recall* dan *Precision,* berguna untuk memastikan model tidak condong hanya pada salah satu matrik. Dan terakhir ROC-AUC untuk mengukur keandalan model dalam membedakan pelanggan yang setia dan pelanggan yang berisiko churn pada berbagai tingkatan *threshold* [9].

Dalam industri penerbangan kesalahan prediksi memiliki konsekuensi finansial yang tidak seimbang. Kasus salah alarm atau *False Positive* model mengira penumpang akan churn padahal sebenarnya loyal, dampak bagi maskapai relatif kecil hanya berupa pemberian perhatian retensi yang terkirim ke salah target atau penumpang yang sebenarnya setia. Kasus lolos deteksi atau *False Negative* penumpang yang sebenarnya sangat kecewa justru diprediksi sebagai puas dan aman dari potensi churn, sehingga maskapai tidak mengambil tindakan dan berdampak merugikan maskapai karena berpotensi kehilangan pelanggan.

Mengingat risiko kehilangan pelanggan jauh lebih berbahaya, penelitian ini memberikan perhatian khusus pada nilai *Recall*. Selain itu ambang batas atau *threshold* model disesuaikan secara strategis misalnya menurunkan dari angka 0,50 menjadi 0,40. Penurunan ini membuat sistem lebih sensitif dalam mendeteksi tanda tanda ketidakpuasan sejak awal, sehingga angka pelanggan churn yang luput dari deteksi dapat ditekan seminimal mungkin.

2.2 Previous Studies

Penelitian mengenai machine learning untuk retensi pelanggan telah banyak dilakukan pada berbagai domain industri, diantaranya adalah Damanik dan Jambak (2023) yan meneliti klasifikasi customer churn pada industri telekomunikasi menggunakan algoritma *Decision Tree*. Penelitian ini berhasil memetakan faktor penggunaan pulsa dan durasi panggilan terhadap status churn pelanggan. Meskipun menghasilkan pohon keputusan yang mudah dipahami, model pohon tunggal menunjukkan keterbatasan stabilitas dan rentan terhadap perubahan distribusi data dengan capaian akurasi pada kisaran 82%–84%.

Lalu ada Shahabiyah, Dikananda, dan Ali (2026) yang menggunakan algoritma *Random Forest* untuk deteksi dini churn pelanggan pada platform e-commerce di Indonesia berbasis CRM. Penelitian ini membuktikan bahwa pendekatan ensemble menghasilkan akurasi yang lebih unggul dibandingkan algoritma tunggal karena mampu mengatasi korelasi antar variabel transaksi. Namun, penelitian ini masih menggunakan *threshold* standar 0,50 tanpa menganalisis sensitivitas *False Negative*, serta belum mengintegrasikan model ke dalam sistem inferensi interaktif.

Studi Kepuasan Penumpang Maskapai beberapa studi internasional yang meneliti dataset Airlines Customer Satisfaction umumnya berfokus pada analisis korelasi statistik dan pemeringkatan variabel yang paling mempengaruhi kepuasan umum. Sebagian besar literatur terdahulu berhenti pada tahap evaluasi metrik matematis di dalam notebook, tanpa menyajikan alur serialisasi model yang dapat dioperasikan secara langsung oleh staf operasional maskapai.

2.3 Comparative Analysis

Berdasarkan penelitian terdahulu, disusun tabel analisis komparatif untuk mengidentifikasi *research gap* dan memposisikan penelitian yang diusulkan. Penelitian ini memposisikan diri untuk mengisi kesenjangan pada literatur sebelumnya melalui beberapa kontribusi seperti memperbesar skala data, membuat rekayasa fitur, penyelarasan threshold dengan risiko bisnis, dan jembatan dari analitik ke operasional.

Parameter Komparasi	Damanik dan Jambak (2023)	Shahabiyah, Dikananda, dan Ali (2026)	Penelitian yang Diusulkan
Domain Kasus	Telekomunikasi	E-Commerce CRM	Airline Satisfaction
Ukuran Dataset	3.100 Baris data	5.000 Baris data	129.880 Baris data
Algoritma yang Diuji	Decision Tree	Random Forest	Logistic Regression, Decision Tree, Random Forest
Model Terbaik	Decision Tree	Random Forest	Random Forest
Rekayasa Fitur	Minimal	Fitur RFM transaksi	Total Delay, Delay Ratio, Agregasi Skor Inflight & Preflight, Segmentasi Usia & Jarak
Eksplorasi Threshold	Tidak ada (Standar 0,50)	Tidak ada (Standar 0,50	Uji coba multi-threshold (0,30-0,50) dan penetapan threshold optimal 0,40 untuk memaksimalkan recall
Segmentasi	Biner (churn/non churn)	Biner (churn/non churn)	Tiga tingkat risiko Low Risk, Medium Risk, dan High Risk
Bentuk Output Akhir	Laporan akademis	Laporan akademis	Paket model, pipeline mandiri, Dashboard web streamlit

BAB III RESEARCH METHODOLOGY

3.1 Research Framework

Penelitian ini disusun mengikuti kerangka kerja analitik berbasis machine learning yang sistematis dan terstruktur ke dalam beberapa tahapan utama, sebagaimana digambarkan dalam alur kerja berikut:

1. Tahap Pengumpulan Data (*Data Collection*), dengan mengambil dan memuat dataset Airlines Customer Satisfaction dari basis data Kaggle.
2. Tahap Pembersihan Data (*Data Cleaning*), memeriksa data duplikat, mendeteksi nilai kosong, dan melakukan penanganan imputasi nilai yang hilang.
3. Tahap Rekayasa Fitur (*Feature Engineering*) membentuk fitur-fitur turunan baru dari data operasional penerbangan dan agregasi skor survei untuk meningkatkan daya pembeda model.
4. Tahap Transformasi Data (*Encoding & Scaling*), Mengubah variabel kategorikal teks menjadi bentuk numerik biner dan One-Hot Encoding, serta menstandarisasi skala fitur numerik.
5. Tahap Pembagian Data (*Train-Test Split*), Membagi dataset secara terstratifikasi menjadi data latih 80% dan data uji 20%.
6. Tahap Pembangunan dan Pelatihan Model (*Model Training*), melatih tiga algoritma klasifikasi, yaitu Logistic Regression sebagai model pembanding dasar, *Decision Tree*, dan *Random Forest* sebagai model utama yang diusulkan.
7. Tahap Evaluasi & Optimasi *Threshold,* mengevaluasi metrik performa model pada data uji serta menganalisis sensitivitas ambang batas keputusan (*decision threshold*) guna menekan risiko False Negative.
8. Tahap Analisis Tingkat Kepentingan Fitur (*Feature Importance*), mengidentifikasi faktor-faktor layanan penerbangan yang paling dominan dalam memicu ketidakpuasan pelanggan.
9. Tahap Deployment dan Antarmuka Interaktif, menyimpan model terbaik ke dalam format serialisasi paket .pkl dan mengintegrasikannya ke dalam dashboard aplikasi web berbasis Streamlit.

3.2 Dataset and Data Collection

Dataset yang digunakan dalam penelitian ini bersumber dari repository public kaggle dengan judul Airlines Customer Satisfaction, dengan deskripsi lebih lengkapnya sebagai berikut :

Informasi	**Keterangan**
Nama dataset	Airlines Customer Satisfaction

Sumber dataset	https://www.kaggle.com/datasets/sjleshrac/airlines-customer-satisfaction?resource=download
Jumlah data	129.880 baris
Jumlah fitur	22 fitur prediktor + 1 target
Periode data	Tidak dicantumkan
Target	Churn
Jumlah Churn	58.793 (45,27%)
Jumlah Non-Churn	71.087 (54,73%)

Deskripsi variabel:

No.	Variable	Type Data	Deskripsi
1	satisfaction	Categorical (target)	Kepuasan pelanggan: satisfied / dissatisfied
2	Gender	Categorical	Jenis kelamin: Female / Male
3	Customer Type	Categorical	Jenis pelanggan: Loyal Customer / disloyal Customer
4	Age	Numeric	Usia pelanggan (7–85 tahun)
5	Type of Travel	Categorical	Tujuan perjalanan: Business travel / Personal Travel
6	Class	Categorical	Kelas penerbangan: Business, Eco, Eco Plus
7	Flight Distance	Numeric	Jarak penerbangan (50–6.951)
8	Seat comfort	Ordinal (0–5)	Penilaian kenyamanan kursi
9	Departure/Arrival time convenient	Ordinal (0–5)	Penilaian kenyamanan jadwal keberangkatan/kedatangan
10	Food and drink	Ordinal (0–5)	Penilaian makanan dan minuman
11	Gate location	Ordinal (0–5)	Penilaian lokasi gerbang
12	Inflight wifi service	Ordinal (0–5)	Penilaian layanan Wi-Fi dalam pesawat
13	Inflight entertainment	Ordinal (0–5)	Penilaian hiburan dalam pesawat
14	Online support	Ordinal (0–5)	Penilaian dukungan daring
15	Ease of Online booking	Ordinal (0–5)	Penilaian kemudahan pemesanan daring
16	On-board service	Ordinal (0–5)	Penilaian layanan di atas pesawat
17	Leg room service	Ordinal (0–5)	Penilaian ruang kaki
18	Baggage	Ordinal (1–5)	Penilaian penanganan bagasi

	handling		
19	Check in service	Ordinal (0–5)	Penilaian layanan check-in
20	Cleanliness	Ordinal (0–5)	Penilaian kebersihan
21	Online boarding	Ordinal (0–5)	Penilaian proses boarding daring
22	Departure Delay in Minutes	Numeric	Keterlambatan keberangkatan (menit)
23	Arrival Delay in Minutes	Numeric	Keterlambatan kedatangan (menit), 393 nilai kosong

3.3 Data Preprocessing

Tahapan ini dilakukan untuk memastikan kualitas dan konsistensi data sebelum Digunakan untuk melatih model.

3.3.1 Data Cleaning

Permasalahan	**Jumlah**	**Penanganan**
Missing value	393	Diimputasi dengan median Arrival Delay pada kelompok Departure Delay yang sama, sisanya dengan median keseluruhan
Duplicate data	0	-
Outlier	Flight Distance 2.581 (2,0%), Departure Delay 18.098 (13,9%), Arrival Delay 17.492 (13,5%), Age 0	Tidak dihapus karena merupakan kejadian nyata (penerbangan jauh, keterlambatan panjang).
Kesalahan format	0	Semua tipe data sudah sesuai, tidak ditemukan juga salah ketik/spasi

3.3.2 Feature Engineering

Fitur	**Proses**	**Alasan**
Total_Delay	Departure Delay + Arrival Delay	Merangkum total dampak delay pada satu penerbangan
Is_Delayed	Bila total delay < 15 Menit	Menandai keterlambatan yang berdampak bagi penumpang
Delay_Ratio	Total_Delay / (Flight Distance + 1) x 100	Menilai keterlambatan relatif terhadap jarak tempuh
Avg_Inflight_Rating	Ratarata 5 penilaian kabin	Meringkas pengalaman di dalam pesawat
Avg_Ground_Service_ Rating	Rata-rata 7 penilaian layanan	Meringkas pengalaman layanan digital dan darat

Age_Group	Gen_Z (≤24), Millennial (25–40), Gen_X (41–55), Boomer (>55)	Merangkap perbedaan perilaku berdasarkan umur
Distance_Category	Short (≤1.000), Medium (≤2.500), Long (>2.500)	Membedakan penerbangan jarak pendek dan jauh

3.3.3 Encoding

Variable	**Metode Encoding**	**Hasil**
Customer Type	Label Encoding	Disloyal = 1, Loyal = 0
Gender	Label Encoding	Male = 1, Female = 0
Satisfaction	Label Encoding	Satisfied = 1, Dissatisfied = 0
Class	One-Hot Encoding	Class_Eco,Class_Eco Plus
Type of Travel	One-Hot Encoding	Type of Travel_Personal
Age_Group	One-Hot Encoding	Millennial, Gen_X,Boomer
Distance_Category	One-Hot Encoding	Medium_Haul, Long_Haul

3.3.4 Scaling

Metode yang digunakan adalah RobustScaler, yang memusatkan data pada median dan melakukan skala dengan rentang antar kuartil. Metode ini dipilih karena Flight Distance dan kedua variabel keterlambatan memiliki banyak outlier, sehingga StandardScaler atau MinMaxScaler akan terpengaruh nilai ekstrim. Proses fit dilakukan hanya pada data latih hasil SMOTE [10], lalu transform diterapkan ke data uji untuk mencegah data leakage. Sesuai kode, scaling diterapkan pada seluruh 33 fitur.

3.4 Proposed Method

Metode utama yang diusulkan dalam penelitian ini adalah algoritma *Random Forest Classifier*. *Random Forest* dipilih karena merupakan metode ensemble berbasis pohon yang sangat tangguh dalam menangani data tabular berdimensi besar dengan interaksi fitur yang kompleks. Model ini bekerja dengan membangun 100 pohon keputusan secara independen, di mana setiap pohon dilatih menggunakan sampel data acak dan subset fitur acak pada setiap titik percabangan. Konfigurasi parameter utama yang diterapkan pada Random Forest dalam penelitian ini meliputi:

- n_estimators = 100: Menggunakan 100 pohon keputusan untuk menghasilkan konsensus prediksi yang stabil.
- max_depth = 14: Membatasi kedalaman maksimum setiap pohon keputusan guna mencegah model menghafal data atau disebut juga *overfitting* dan menjaga kemampuan generalisasi pada data baru.
- random_state = 42: Memastikan hasil pelatihan bersifat konsisten dan dapat direproduksi.
- n_jobs = -1: Memanfaatkan seluruh inti prosesor komputer untuk mempercepat komputasi pelatihan data berskala besar.

3.5 Experimental Design

Skenario *Data Splitting* dataset yang telah diproses dibagi dengan porsi 80% untuk data dilatih dan 20% untuk data yang diuji. Pembagian dilakukan menggunakan metode *stratified random sampling* dengan parameter stratify=y dan random_state=42, sehingga proporsi kelas churn yang digunakan untuk melatih model jumlahnya 103.904 baris dan data untuk pengujian sebanyak 25.976 baris tetap seimbang pada angka 45,27%.

Skenario pemodelan pembanding menggunakan tiga algoritma dilatih menggunakan data latih yang identik. *Logistic Regression* dilatih menggunakan data yang telah distandarisasi dengan parameter max_iter=1000 dan penalti regulasi L2. *Decision Tree* dilatih dengan pembatasan kedalaman simul max_depth=12 dan kriteria pemisah Gini. *Random Forest* dilatih dengan 100 pohon keputusan dan kedalaman maksimal max_depth=14.

Skenario *Decision Threshold Tuning* probabilitas churn kontinu yang dihasilkan oleh model terbaik diuji coba pada *threshold* 0.30, 0.35, 0.40, 0.45, dan 0.50 untuk menganalisis pergeseran metrik evaluasi dan memilih *threshold* keputusan yang paling optimal untuk melihat probabilitas pelanggan yang churn.

3.6 Evaluation Matrics

Evaluasi performa model pengujian diukur menggunakan *confusion matrix* yang memetakan perbandingan antara status aktual dan hasil prediksi, serta dijabarkan ke dalam lima metrik kinerja utama. Akurasi digunakan untuk mengetahui persentase ketepatan model secara menyeluruh terhadap seluruh data uji. Presisi mengukur tingkat keakuratan model saat memprediksi label churn, yaitu seberapa banyak penumpang yang benar-benar churn dari keseluruhan penumpang yang diprediksi churn. Sementara itu, *Recall* atau sensitivitas mengukur kemampuan model dalam menjaring seluruh penumpang yang sesungguhnya mengalami ketidakpuasan atau churn dari total populasi churn yang ada. Untuk menjaga keseimbangan penilaian, nilai F1-Score dihitung sebagai rata-rata harmonik antara Presisi dan *Recall*. Metrik ini menjadi rujukan utama untuk memastikan performa model tetap optimal pada kedua aspek tanpa mengalami bias sepihak.

Selain itu, kurva *Receiver Operating Characteristic* beserta nilai luas area di bawahnya (ROC-AUC) dihitung untuk memvalidasi keandalan daya pembeda model dalam memisahkan kelas pelanggan puas dan tidak puas pada seluruh rentang nilai *Threshold* probabilitas. Dalam konteks bisnis maskapai penerbangan, penelitian ini memberikan bobot prioritas tertinggi pada metrik *Recall* dan F1-Score. Hal ini didasari oleh pertimbangan biaya kesalahan klasifikasi yang bersifat asimetris, dimana kerugian akibat kegagalan mendeteksi penumpang atau disebut *False Negative* jauh lebih besar dan berisiko menghilangkan nilai seumur hidup

pelanggan dibandingkan dengan kekeliruan mengirimkan program retensi kepada penumpang yang sebenarnya loyal atau *False Positive*

BAB IV RESULTS

4.1 Experimental Result

Pengujian dilakukan terhadap data uji sebanyak 25.976 baris data pelanggan yang dipisahkan secara *stratified sampling* untuk menjaga proporsi kelas churn sebesar 45,27% kinerja masing-masing model diuji berdasarkan *Confusion Matrix* serta matrik turunan yang mencakup *accuracy, precision, recall, f1-score,* dan *ROC-AUC*. *Logistic Regression* menghasilkan 12.005 true negative, 2.162 false positive, 2.101 false negative, dan 9.658 true positive. Model ini menghasilkan angka false negative tertinggi sejumlah 2.101 pelanggan churn luput terdeteksi. *Decision Tree* menghasilkan 13.411 true negative, 972 false positive, 511 false negative, dan 11.248 true positive. Terjadi penurunan drastis pada angka false negative menjadi 511 pelanggan. *Random Forest* menghasilkan 13.414 true negative, 803 false positive, 643 false negative, dan 11.116 true positive. Mode ini memberikan jumlah prediksi benar tertinggi serta angka false negative paling rendah.

4.2 Comparative Performance

Berikut merupakan matrik perbandingan hasil dari ketiga model yang diuji berdasarkan Accuracy, Precision, Recall, F1-Score, dan ROC-AUC sesuai kebutuhan.

Model	**Accuracy**	**Precision**	**Recall**	**F1-Score**	**ROC-AUC**
Logistic Regression	83,5%	81,7%	82,1%	81,9%	0,9088
Decision Tree	94,2%	92,05%	95,6%	93,8%	0,9855
Random Forest	94,4%	93,2%	94,5%	93,9%	0,9894

Tabel 4.1 Matrik Model

Interpretasi hasil:

- Logistic Regression memberikan performa paling rendah karena asumsi linieritas kurang mampu menangkap hubungan kompleks antara fitur kepuasan layanan yang bersifat non linear
- Decision Tree menunjukan peningkatan performa yang signifikan, namun cenderung lebih rentan terhadap overfitting pada aturan percabangan yang dalam.
- Random Forest memberikan performa yang terbaik dibanding lainya, kombinasi ensemble dari banyak pohon keputusan membuat model ini paling stabil, memiliki Recall yang tinggi untuk meminimalisir kesalahan False Negative, serta nilai ROC-UAC yang mendekati angka 1,0

4.2.1 Champion Model

Berdasarkan evaluasi komparatif tersebut, *Random Forest* ditetapkan sebagai model terbaik. *Random Forest* dipilih karena menawarkan keseimbangan optimal antara Presisi dan *Recall*, stabilitas generelasisai yang sangat tinggi berkat mekanisme *ensemble bagging,* serta nilai ROC-AUC yang mendekati angka 1,0 yang membuktikan keandalan pemisahan kelas pelanggan puas dan tidak puas.

4.3 Statistical Validation

Validasi statistik dilakukan untuk memastikan bahwa performa unggul yang dicapai model tidak disebabkan oleh kebetulan atau penghafalan data. Validasi ini ditunjukan melalui beberapa bukti empiris. Konsistensi metrik ROC-AUC nilai *Random Forest* sebesar 0,9894 membuktikan bahwa kemampuan diskriminasi model berada pada kategori *outstanding* di seluruh spektrum *Threshold* probabilitas, jauh melampaui garis tebakan acak. Stabilitas Data Uji, pengujian dilakukan pada 25.976 sampel data uji independen yang tidak pernah dilihat oleh model dalam proses pelatihan. Kestabilan nilai F1-Score pada level 93,89% membuktikan bahwa model memiliki kemampuan generalisasi yang sangat kuat terhadap variansi populasi pelanggan baru. Kekuatan *Ensemble Tree,* latihan yang melibatkan agregasi 100 pohon keputusan secara independen terbukti memangkas variansi kesalahan klasifikasi model secara konsisten tanpa mengorbankan kecepatan inferensi data operasional.

4.4 Sensitivity and Ablation Analysis

Tingkat kepentingan variabel dianalisis menggunakan bobot Gini Importance pada model *Random Forest* untuk mengetahui faktor yang paling mempengaruhi keputusan churn pelanggan.

Peringkat	Fitur	Importance	Interpretasi
1	Inflight Entertainment	0,1838	Hiburan yang tersedia saat penerbangan menjadi faktor paling utama yang menentukan kepuasan pelanggan menggunakan maskapai tersebut
2	Seat Comfort	0,1259	Kenyamanan tempat duduk memegang peranan penting dalam penilaian keseluruhan pengalaman penerbangan
3	Preflight_Online_Score	0,0720	Kemudahan proses online kualitas layanan maskapai

			pada fase sebelum penerbangan memiliki pengaruh pada kepuasan pelanggan
4	Ease of Online Booking	0,0702	Kemudahan proses melakukan booking melalui online berpengaruh pada kepuasan pelanggan
5	Inflight_Service_Score	0,0536	Kualitas pelayanan selama penerbangan berpengaruh pada bagaimana pelanggan akan merasa nyaman pada penerbangan tsb

4.4.1 *Decision Threshold Tuning*

Dalam bisnis maskapai penerbangan, biaya akibat gagal mendeteksi pelanggan churn atau *false negative* jauh lebih besar daripada risiko salah alarm atau *false positive*. Oleh karena itu, dilakukan analisis sensitivitas dengan menguji beberapa tingkatan *threshold.*

Threshold	Akurasi	Presisi	Recall	F1-Score	False Negative
0,50	94,43%	93,26%	94,53%	93,89%	643 Pelanggan
0,45	94,34%	91,90%	95,95%	93,88%	476 Pelanggan
0,40	**94,14%**	**90,50%**	**97,27%**	**93,77%**	**321 Pelanggan**
0,35	93,60%	88,81%	98,24%	93,29%	207 Pelanggan
0,30	92,99%	87,20%	99,05%	92,75%	112 Pelanggan

Hasil analisis pada tabel menunjukan bahwa menurunkan *threshold* dari 0,50 ke 0,40 berhasil meningkatkan *Recall* dari 94,53% menjadi 97,27% serta memangkas jumlah pelanggan churn yang luput dari deteksi dari 643 menjadi hanya 321 pelanggan turun hampir 50%. Dengan penurunan akurasi yang sangat minimal, oleh karena itu *threshold* 0,40 ditetapkan sebagai *threshold* operasional pada sistem retensi.

BAB V DISCUSSION

5.1 Interpretation of Findings

Keberhasilan algoritma *Random Forest* dalam mengungguli *Logistic Regression* dan *Decision Tree* menegaskan bahwa hubungan antara aspek layanan penerbangan dan keputusan pelanggan bersifat sangat kompleks dan non-linier. Ketidakpuasan penumpang tidak dipicu oleh satu variabel tunggal secara terpisah, melainkan merupakan akumulasi dari beberapa titik interaksi selama perjalanan. Analisis kepentingan fitur membuktikan bahwa fasilitas fisik dan pengalaman langsung di dalam kabin pesawat, khususnya Inflight entertainment sebesar 18,38% dan Seat comfort pada angka 12,59%, memegang peranan paling dominan dalam menentukan kepuasan penumpang. Hal ini sangat rasional secara psikologis dan operasional. Selama penerbangan berlangsung, penumpang menghabiskan sebagian besar waktunya duduk di kursi kabin. Kenyamanan ergonomis tempat duduk serta ketersediaan sistem hiburan yang berfungsi dengan baik menjadi fokus interaksi utama penumpang. Ketika layar sentuh hiburan rusak atau ruang kursi terasa sempit dan tidak nyaman, persepsi negatif penumpang terhadap maskapai akan terbentuk secara instan dan membekas lama.

Di sisi lain, fitur layanan digital pra-terbang seperti Preflight Online Score dan Ease of Online booking menempati urutan pengaruh tertinggi berikutnya. Pengalaman reservasi tiket dan check-in daring yang mulus menjadi penentu ekspektasi awal penumpang. Apabila fase pra-terbang sudah diwarnai kendala teknis dan kemudian diperparah oleh akumulasi keterlambatan jadwal penerbangan, penumpang yang berada di kelas ekonomi atau yang belum terikat program loyalitas memiliki kecenderungan paling tinggi untuk langsung beralih ke maskapai pesaing.

Interpretasi segmentasi risiko membuktikan bahwa model mampu memetakan data pengujian ke dalam batas pemisah yang sangat tegas. Segmen Risiko Rendah terbukti sangat akurat dengan tingkat churn riil hanya 0,89%, sedangkan segmen Risiko Tinggi memiliki tingkat churn aktual mencapai 97,35%. Pemisahan yang tajam ini memberikan kepastian analitik bagi manajemen maskapai bahwa tindakan penyelamatan retensi dapat dipusatkan secara presisi pada kelompok penumpang berisiko tinggi tanpa menghamburkan anggaran promosi pada pelanggan yang sudah loyal.

5.2 Comparison with Previous Studies

Temuan dalam penelitian ini memperkuat sekaligus melengkapi hasil-hasil penelitian terdahulu mengenai klasifikasi customer churn: Jika dibandingkan dengan penelitian Damanik dan Jambak (2023) yang menguji algoritma *Decision Tree* pada industri telekomunikasi dengan capaian akurasi 82%–84%, penelitian ini membuktikan bahwa pendekatan ensemble dari *Random Forest* menghasilkan stabilitas dan ketepatan prediksi yang jauh lebih superior akurasi 94,43% dan ROC-AUC 0,9894. Penggunaan ratusan pohon keputusan terbukti efektif memangkas kelemahan *Decision Tree* yang mudah mengalami overfitting pada aturan percabangan yang dalam. Sementara itu, dibandingkan dengan studi Shahabiyah, Dikananda, dan Ali (2026) yang menerapkan Random Forest pada e-commerce namun hanya berfokus pada batas klasifikasi standar 0,50, penelitian ini melangkah lebih jauh dengan menyertakan *threshold tuning*. Penurunan *threshold* ke angka 0,40 terbukti mampu menaikkan nilai *Recall* dari 94,53% menjadi 97,27% serta memangkas separuh angka False Negative. Langkah penyelarasan threshold ini menjadi pembeda penting karena secara nyata merespons kebutuhan industri penerbangan yang memprioritaskan penangkapan pelanggan kecewa sebanyak mungkin.

5.3 Scientific and Practical Implications

Secara konseptual, penelitian ini memperkaya literatur kecerdasan bisnis pada sektor transportasi udara non-kontraktual. Penelitian ini membuktikan bahwa data survei kepuasan pelanggan multidimensi yang dikombinasikan dengan data keterlambatan operasional dan rekayasa fitur agregat seperti *Inflight Score, Preflight Score,* dan *Delay Ratio* dapat menjadi basis data prediktif yang andal dalam memodelkan proksi churn pada skala data sebesar 129.880 baris.

Secara praktis, hasil penelitian ini memberikan panduan aksi operasional nyata bagi divisi CRM dan pemasaran maskapai melalui matriks intervensi retensi bertingkat. Pelanggan Risiko Tinggi >70%, mendapatkan prioritas intervensi penanganan cepat dalam waktu 1x24 jam pasca-penerbangan melalui kontak personal tim customer care, pemberian kompensasi voucher diskon 20%–25% untuk pemesanan tiket berikutnya, serta penawaran fasilitas akses lounge gratis. Pelanggan Risiko Sedang >30%–70%, didekati secara proaktif melalui pengiriman survei kepuasan singkat terkait keluhan spesifik yang dialami serta pemberian insentif poin frequent flyer. Pelanggan Risiko Rendah 0%–30%, dipertahankan melalui program apresiasi loyalitas reguler dan penawaran paket rute favorit.

Untuk menjembatani model analitik dengan kebutuhan operasional harian, penelitian ini mengintegrasikan paket model serialisasi ke dalam aplikasi web interaktif berbasis Streamlit. Aplikasi ini menyediakan dua fitur utama yang siap pakai bagi petugas maskapai yaitu prediksi satu pelanggan, yang memungkinkan staf layanan pelanggan memasukkan profil penerbangan individu secara instan untuk melihat probabilitas churn, kategori risiko,

grafik pendorong risiko, dan rekomendasi intervensi. Prediksi Banyak Pelanggan atau *Batch*, yang emungkinkan tim analitik mengunggah file CSV atau Excel berisi ratusan hingga ribuan data penumpang untuk memproses prediksi massal secara otomatis dan mengunduh hasilnya kembali dalam format CSV/Excel.

5.4 Research Limitations

Penelitian ini memiliki beberapa keterbatasan yang perlu diperhatikan. Penggunaan Proksi Ketidakpuasan, label churn ditentukan berdasarkan proksi ketidakpuasan yaitu dissatisfied pada survei kepuasan, bukan berdasarkan data pembatalan tiket riil atau berhentinya transaksi secara langsung pada sistem reservasi. Keterbatasan Atribut Finansial, dataset tidak memuat informasi variabel moneter seperti harga tiket, kelas tarif promo, dan riwayat frekuensi pembelian tahunan, yang berpotensi meningkatkan akurasi estimasi nilai ekonomi pelanggan. Sifat Data Statis, data yang dianalisis merupakan potret data pada satu rentang waktu survei, sehingga belum menangkap dinamika perubahan tren kepuasan pelanggan secara deret waktu.

BAB VI CONCLUSION

6.1 Research Limitations

Berdasarkan hasil analisis, eksperimen pemodelan, dan evaluasi yang telah dilakukan, dapat diambil beberapa kesimpulan utama. Model algoritma random forest classifier terbukti sebagai model terbaik dalam memprediksi churn penumpang maskapai dengan Akurasi sebesar 94,43%, Presisi 93,26%, Recall 94,53%, F1-Score 93,89%, dan nilai ROC-AUC mencapai 0,9894, mengungguli *Decision Tree* dan *Logistic Regression* secara konsisten. Faktor penentu utamanya adalah kualitas fasilitas di dalam kabin pesawat, khususnya hiburan dalam penerbangan dengan bobot 18,38% dan kenyamanan tempat duduk dengan bobot 12,59%, merupakan dua faktor paling dominan yang mempengaruhi kepuasan dan keputusan retensi penumpang. Efektivitas angka *threshold* keputusan dari standar 0,50 menjadi 0,40 berhasil mendongkrak nilai Recall hingga 97,27% dan memangkas jumlah pelanggan churn yang luput deteksi sebesar 50% dari 643 menjadi 321 pelanggan, sehingga sangat efektif meminimalkan risiko kerugian finansial akibat kehilangan pelanggan. Model berhasil melakukan segmentasi risiko berhasil memetakan penumpang ke dalam tiga zona risiko terukur, di mana segmen risiko tinggi mencakup 39,59% penumpang dengan tingkat churn aktual mencapai 97,35%, yang menjadi sasaran utama program penyelamatan retensi.

6.2 Contribution

Penelitian ini memberikan kontribusi nyata baik dari sisi metodologis maupun praktis. Dari segi kontribusi metodologis menghasilkan alur rekayasa fitur terstruktur khusus domain penerbangan seperti agregasi skor pra-terbang, skor kabin, dan rasio keterlambatan terhadap jarak tempuh, serta membuktikan pentingnya penyesuaian threshold keputusan berbasis pertimbangan biaya bisnis asimetris. Kontribusi implementatif menghasilkan artefak sistem yang siap digunakan langsung di lingkungan operasional, meliputi paket model serialisasi mandiri, modul alur pra-pemprosesan airline_pipeline.py, dan antarmuka dashboard aplikasi web interaktif berbasis Streamlit yang mendukung prediksi perorangan maupun pemrosesan berkas data massal.

6.3 Future Research

Untuk menyempurnakan penelitian ini ke depan, ada beberapa arah pengembangan lanjutan yang disarankan. Pertama eksplorasi algoritma mutakhir dengan menerapkan algoritma Gradient Boosting modern seperti XGBoost, LightGBM, atau CatBoost, serta melakukan optimasi hiperparameter berbasis *Bayesian Optimization* untuk meningkatkan performa prediksi lebih lanjut. Lalu pengayaan fitur transaksional dan sentimen dengan menggabungkan data survei kepuasan dengan data riwayat transaksi tiket, margin keuntungan per rute penerbangan, serta data analisis sentimen teks ulasan penumpang dari media sosial atau situs ulasan perjalanan. Terakhir integrasi operasional real-time yaitu mengembangkan sistem antarmuka berbasis antarmuka pemrograman aplikasi yang terhubung langsung secara real-time dengan sistem check-in bandara, sehingga staf darat maupun awak kabin dapat mendeteksi dan memberikan perlakuan khusus kepada penumpang berisiko tinggi sebelum keberangkatan

DAFTAR PUSTAKA

[1] S. D. Damanik dan M. I. Jambak, "Klasifikasi Customer Churn pada Telekomunikasi Industri Untuk Retensi Pelanggan Menggunakan Algoritma C4.5," KLIK: Kajian Ilmiah Informatika dan Komputer, vol. 3, no. 6, hal. 829–838, Jun. 2023, doi: 10.30865/klik.v3i6.829.

[2] A. P. Shahabiyah, A. R. Dikananda, dan I. Ali, "Deteksi Dini Churn Pelanggan E-Commerce Berbasis CRM di Indonesia Menggunakan Algoritma Random Forest," Buffer Informatika, vol. 12, no. 1, hal. 56–66, 2026, doi: 10.25134/buffer.v12i1.566.

[3] F. F. Reichheld and W. E. Sasser, "Zero Defections: Quality Comes to Services," Harvard Business Review, vol. 68, no. 5, hal. 105–111, 1990.

[4] A. K. Ahmad, A. Jafar, and D. Aljoumaa, "Customer Churn Prediction in Telecom Using Machine Learning in Big Data Platform," Journal of Big Data, vol. 6, no. 1, hal. 1–24, 2019, doi: 10.1186/s40537-019-0191-6.

[5] A. Payne and P. Frow, "A Strategic Framework for Customer Relationship Management," Journal of Marketing, vol. 69, no. 4, hal. 167–176, 2005, doi: 10.1509/jmkg.2005.69.4.167.

[6] A. K. Ahmad, A. Jafar, and D. Aljoumaa, "Customer Churn Prediction in Telecom Using Machine Learning in Big Data Platform," Journal of Big Data, vol. 6, no. 1, hal. 1–24, 2019, doi: 10.1186/s40537-019-0191-6.

[7] D. W. Hosmer, S. Lemeshow, and R. X. Sturdivant, Applied Logistic Regression, 3rd ed. Hoboken, NJ: John Wiley & Sons, 2013.

[8] J. R. Quinlan, "Induction of Decision Trees," Machine Learning, vol. 1, no. 1, hal. 81–106, 1986, doi: 10.1007/BF00116251.

[9] T. Fawcett, "An Introduction to ROC Analysis," Pattern Recognition Letters, vol. 27, no. 8, hal. 861–874, 2006, doi: 10.1016/j.patrec.2005.10.010.

[10] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," Journal of Artificial Intelligence Research, vol. 16, hal. 321–357, 2002, doi: 10.1613/jair.953.

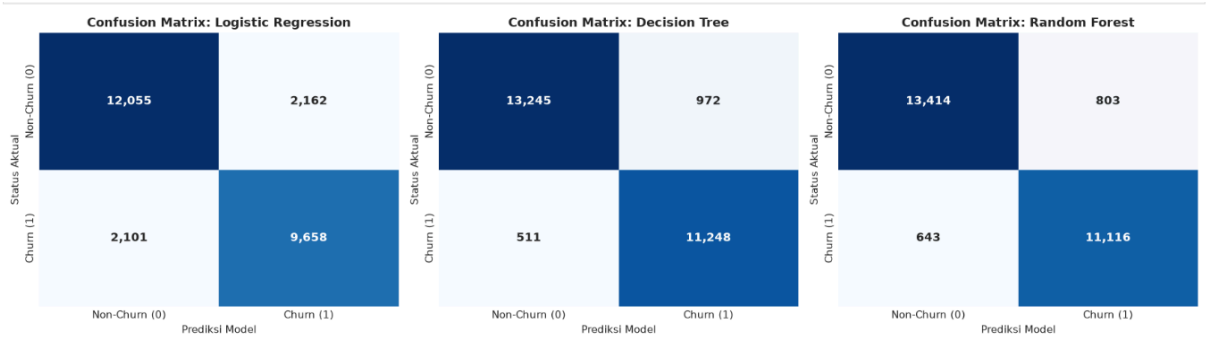
LAMPIRAN

- Source code Python, Streamlit, dan PKL Model. https://drive.google.com/drive/folders/1F8FoKLAFRJ1BeohmIPT9VnvwFsPwQz0m?usp=sharing

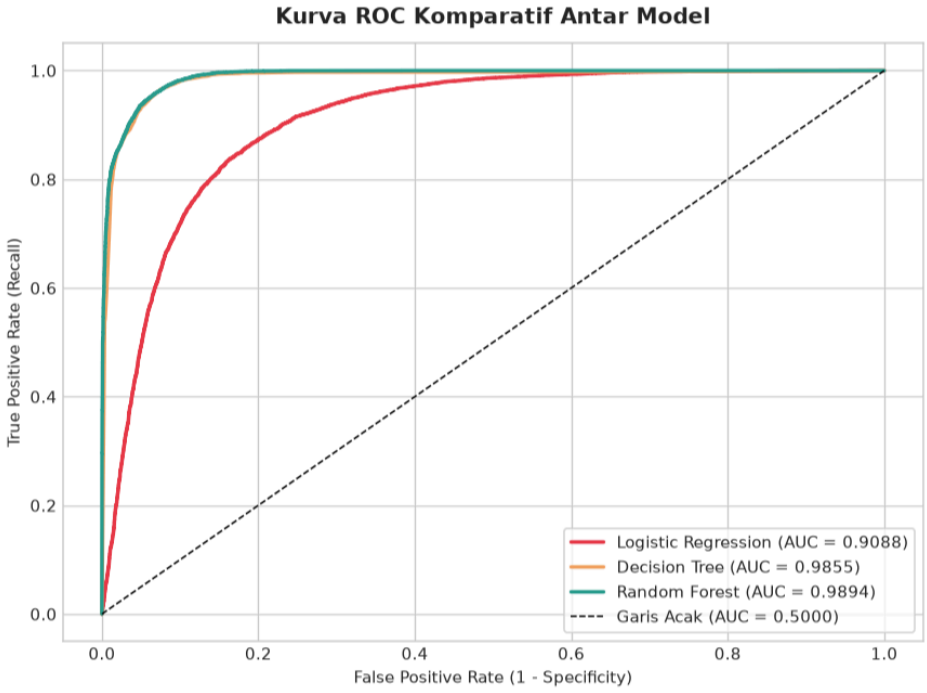
- Output lengkap pemodelan.

	Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	Waktu Training (detik)
0	Random Forest	0.9443	0.9326	0.9453	0.9389	0.9894	2.42
1	Decision Tree	0.9429	0.9205	0.9565	0.9382	0.9855	1.05
2	Logistic Regression	0.8359	0.8171	0.8213	0.8192	0.9088	0.22

- Confusion Matrix.



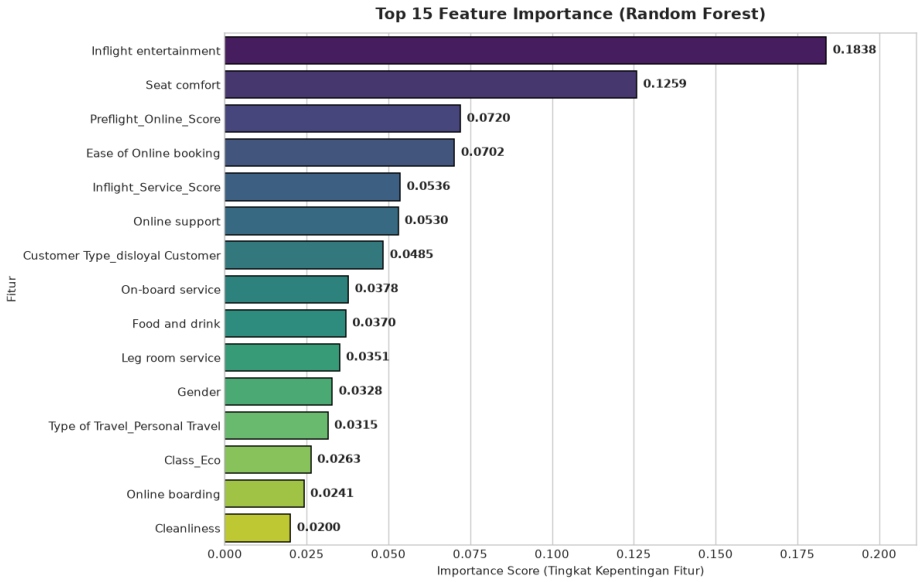
- Grafik ROC.



- Hasil preprocessing.

No	Tahapan Preprocessing	Kondisi Sebelum Preprocessing	Metode / Teknik Penanganan	Kondisi Setelah Preprocessing
1	**Missing Value Imputation**	Kolom Arrival Delay in Minutes memiliki 393 nilai kosong (NaN).	Imputasi nilai Median (median keterlambatan = 0,0 menit).	Tidak ada nilai kosong (0 missing values), seluruh 129.880 data lengkap dan utuh.
2	**Target Formulation**	Kolom satisfaction bertipe teks ('neutral or dissatisfied' vs 'satisfied').	Transformasi Biner: • neutral or dissatisfied $\rightarrow$ 1 (Churn) • satisfied $\rightarrow$ 0 (Non-Churn)	Variabel target biner Churn terbentuk: • 0 (Non-Churn): 71.087 (54,7%) • 1 (Churn): 58.793 (45,3%)
3	**Feature Engineering**	Data waktu delay dan kepuasan layanan masih terpisah per sub-komponen.	• Total Delay = Delay Keberangkatan + Delay Kedatangan. • Overall_Service_Score = Rata-rata 14 fitur layanan.	Terbentuk 2 fitur agregat baru yang meningkatkan performa prediksi model.
4	**Categorical Encoding**	Kolom kategorikal teks: Gender, Customer Type, Type of Travel, Class.	Pemetaan Numerik (Label / Binary Mapping): • Gender: Male=1, Female=0 • Customer Type: Loyal=1, Disloyal=0 • Class: Eco=0, Eco Plus=1, Business=2	Seluruh fitur kategorikal berubah menjadi tipe data numerik siap komputasi.
5	**Feature Scaling**	Skala fitur tidak seragam (rentang ratusan/ribuan vs skala survei 1–5).	**StandardScaler (Z-Score Normalization) dengan nilai mean $\mu = 0$ dan varians $\sigma^2 = 1$.**	Fitur numerik terstandarisasi, mencegah dominasi variabel berdimensi besar.

- Feature Importance.



- Hasil prediksi seluruh pelanggan.

```
Distribusi Kategori Risiko pada Seluruh Pelanggan:
risk_category
Low Risk       64894
High Risk      53403
Medium Risk    11583
Name: count, dtype: int64
```

	Loyalty Number	actual_churn	probability_churn	risk_category
0	221958	0	0.016455	Low Risk
1	771155	0	0.114211	Low Risk
2	231932	0	0.033124	Low Risk
3	465838	0	0.030373	Low Risk
4	359178	0	0.006745	Low Risk
5	744167	0	0.050602	Low Risk
6	210268	0	0.053703	Low Risk
7	832180	0	0.058513	Low Risk
8	154886	0	0.104853	Low Risk
9	237337	0	0.076016	Low Risk